



# **Internacionalização da agricultura brasileira e os efeitos nos preços, disponibilidade e consumo de alimentos no Brasil**

---

**Pesquisador:** Jonatan Alexandre Oliveira

**Orientador:** Prof. Dr. José Giacomo Baccarin

**Responsáveis pela análise:**

Alex Rodrigo dos Santos Souza  
Chang Chiann  
Gustavo de Oliveira Kanno  
Rodrigo Marcel Araujo Oliveira  
Victor Ribeiro Baião Decanini

# AGENDA



Contexto

Objetivo

Técnicas Utilizadas

Testes Estatísticos

Série Temporal

Correlações

Regressões

# AGENDA



Contexto

Objetivo

Técnicas Utilizadas

Testes Estatísticos

Série Temporal

Correlações

Regressões

# CONTEXTO

---

- ❖ A agricultura no Brasil vem sofrendo mudanças ano após ano, principalmente na questão de importação e exportação.
- ❖ Essas mudanças refletem no mercado interno brasileiro, alterando:
  - preços
  - qualidade dos produtos
  - disponibilidade
  - forma de consumo
- ❖ Aumento significativo dos preços relativos da alimentação quando comparado com outras despesas familiares

# AGENDA



```
graph LR; A[AGENDA] --- B[Contexto]; A --- C[Objetivo]; A --- D[Técnicas Utilizadas]; A --- E[Testes Estatísticos]; A --- F[Série Temporal]; A --- G[Correlações]; A --- H[Regressões];
```

Contexto

Objetivo

Técnicas Utilizadas

Testes Estatísticos

Série Temporal

Correlações

Regressões

# OBJETIVO

---

- ❖ Procurar identificar quais cadeias de alimentos têm um maior impacto na variação de preços em função do IPCA para uma determinada cadeia de interesse
- ❖ Verificar se há correlação entre a variação do preço em função do IPCA de diferentes cadeias agropecuárias de produtos ao longo do tempo

# AGENDA



Contexto

Objetivo

Técnicas Utilizadas

Testes Estatísticos

Série Temporal

Correlações

Regressões

# TÉCNICAS UTILIZADAS

---

- ❖ Média dos IPCA's dos subitens para descrever o IPCA de cada cadeia
- ❖ Teste de Dickey-Fuller e Phillips-Perron para testar se há raiz unitária
- ❖ Função de Autocorrelação para identificar correlação dentro de uma única cadeia
- ❖ Função de Autocorrelação Parcial para identificar correlação dentro de uma única cadeia
- ❖ Correlação Cruzada para identificar correlação entre as cadeias
- ❖ Regressão LASSO para ponderar o impacto (pesos) de cada cadeia em uma cadeia de interesse
- ❖ Regressão clássica no contexto de séries temporais para compreender melhor o funcionamento da série
- ❖ Regressão com erros autocorrelacionados (ARIMA)
- ❖ Teste Ljung-Box para ARIMA(p,d,q)



# AGENDA



```
graph LR; A[AGENDA] --- B[Contexto]; A --- C[Objetivo]; A --- D[Técnicas Utilizadas]; A --- E[Testes Estatísticos]; A --- F[Série Temporal]; A --- G[Correlações]; A --- H[Regressões];
```

Contexto

Objetivo

Técnicas Utilizadas

**Testes Estatísticos**

Série Temporal

Correlações

Regressões

# TESTES DE DICKEY-FULLER e PHILLIPS-PERRON

- ❖ Hipótese nula: Afirma que há presença de raiz unitária, ou seja, série não estacionária
- ❖ Hipótese alternativa: Afirma que não há raiz unitária, ou seja, série é estacionária
- ❖  $\beta_1$  : Intercepto do modelo
- ❖  $\beta_2$  : Coeficiente de tendência
- ❖  $\delta$  : Coeficiente de presença de raiz unitária

$$\Delta y_t = \beta_1 + \beta_2 t + \delta y_{t-1} + \sum_{i=1}^m \alpha_i \Delta y_{t-i} + \varepsilon_t$$

- ❖ Estatística de teste T de Dickey-Fuller
- ❖ Tabelados por Dickey-Fuller através de simulação Monte Carlo

$$T = \frac{\hat{\delta}}{se(\hat{\delta})}$$

- ❖ Estatística de teste Z de Phillips-Perron
- ❖ Z é um ajuste na estatística de Dickey-Fuller

$$Z = n\hat{\delta}_n - \frac{n^2\hat{\sigma}^2}{2s_n^2} \left( \hat{\lambda}_n^2 - \hat{\gamma}_{0,n} \right)$$

# AGENDA



```
graph LR; A[AGENDA] --- B[Contexto]; A --- C[Objetivo]; A --- D[Técnicas Utilizadas]; A --- E[Testes Estatísticos]; A --- F[Série Temporal]; A --- G[Correlações]; A --- H[Regressões];
```

Contexto

Objetivo

Técnicas Utilizadas

Testes Estatísticos


Série Temporal

Correlações

Regressões

# SÉRIE TEMPORAL DA BOVINOCULTURA

Série Temporal da Bovinocultura



- ❖ Não há indícios de componente sazonal
- ❖ Observa-se uma grande variação do IPCA em torno de uma reta positiva, principalmente no período dos anos de 2013 a 2017, com destaque para 2011, indicando assim um aumento no preço continuamente.
- ❖ Teste de Dickey-Fuller e Teste de Phillips-Perron: o p-valor é de 0,01 para a série
- ❖ Rejeitamos a hipótese nula de que a série temporal contém uma raiz unitária.

# FUNÇÃO DE ACF e PACF

❖ A autocorrelação é definida como correlação entre duas observações em instantes diferentes. A autocorrelação de lag um caracteriza séries onde uma observação está correlacionada com a observação imediatamente anterior ou posterior (fevereiro e janeiro, ou fevereiro e março, por exemplo)

❖ A função de autocovariância amostral entre duas observações de lag  $k$  é definida como:

$$c_k = \frac{1}{n} \sum_{t=1}^{n-k} (x_t - \bar{x})(x_{t+k} - \bar{x})$$

❖ A função de autocorrelação amostral de lag  $k$  é :

$$r_k = \frac{c_k}{c_0} = \text{Corr}(x_t, x_{t+k})$$

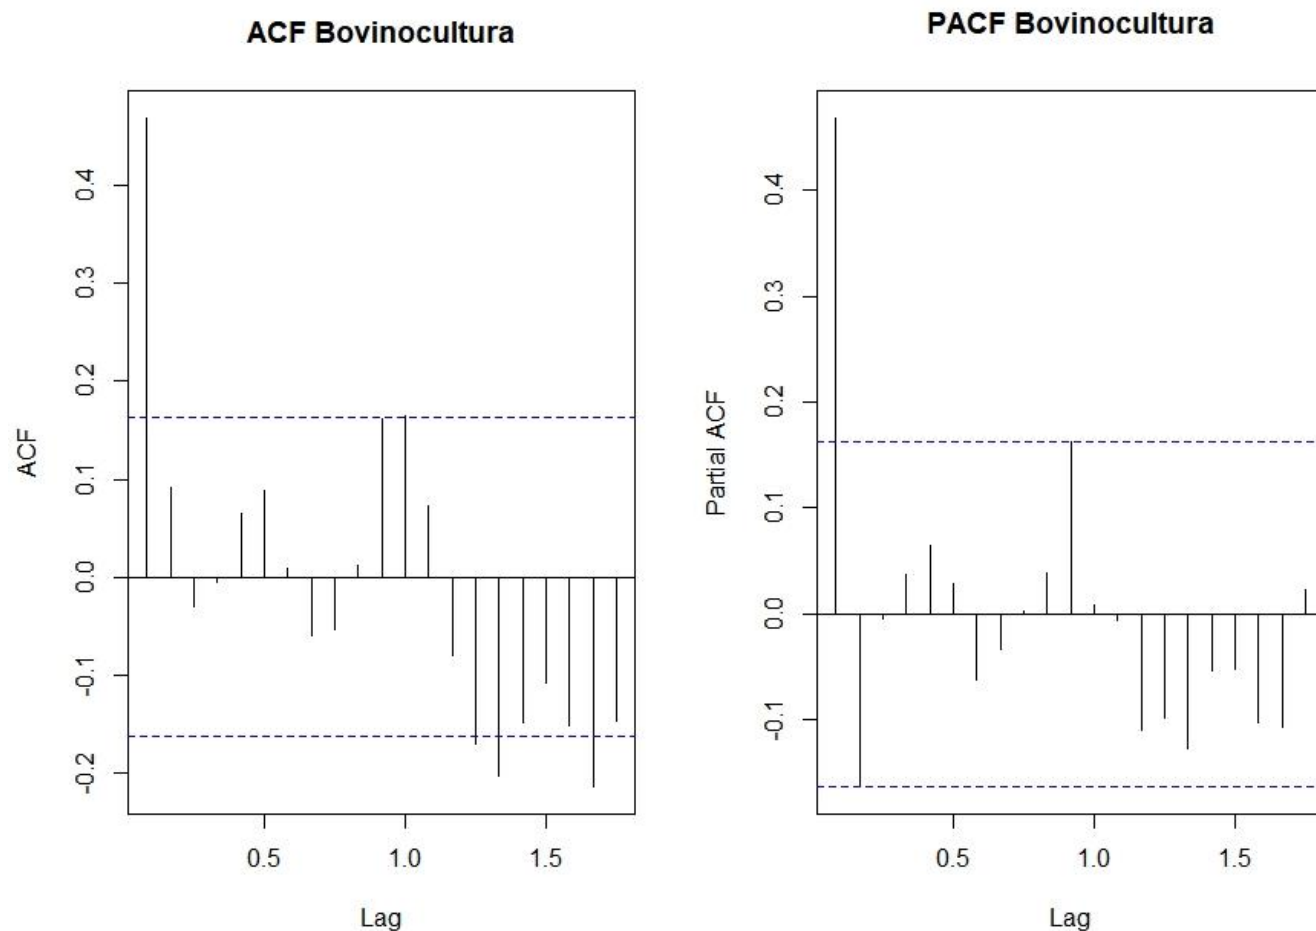
❖ O intervalo de confiança de aproximadamente 95% para ACF pode ser construído por:

$$r_k \pm \frac{2}{\sqrt{n}}$$

❖ A função de autocorrelação parcial (PACF) mede a correlação entre  $X_t$  e  $X_{t-k}$  eliminando a influência  $X_{t-1}, \dots, X_{t-k+1}$ :

$$f_k = \begin{cases} \text{Corr}(X_t, X_{t+k}) = r_1 & \text{se } k = 1 \\ \text{Corr}(X_{t+k} - X_t^{k-1}, X_t - X_t^{k-1}) & \text{se } k > 1 \end{cases}$$

# FUNÇÃO DE AUTOCORRELAÇÃO



- ❖ Notamos que temos um pico no primeiro lag do ACF e do PACF, ambos fora do intervalo de confiança, isso significa que esta observação está correlacionada positivamente com a observação imediatamente anterior.

# AGENDA



- Contexto
- Objetivo
- Técnicas Utilizadas
- Testes Estatísticos
- Série Temporal
- Correlações
- Regressões

# CORRELAÇÃO CRUZADA

---

- ❖ Representa as correlações entre duas séries temporais em diferentes períodos de tempo
- ❖ Pode ajudar a entender se uma série de dados "conduz" uma outra série, e até que ponto isso acontece

❖ Correlação cruzada amostral dada por:


$$\hat{\rho}_{xy}(h) = \frac{\hat{\gamma}_{xy}(h)}{\sqrt{\hat{\gamma}_x(0)\hat{\gamma}_y(0)}}.$$

Com:

$$\hat{\gamma}_{xy}(h) = n^{-1} \sum_{t=1}^{n-h} (x_{t+h} - \bar{x})(y_t - \bar{y}),$$




# CORRELAÇÃO CRUZADA DA BOVINOCULTURA




# CORRELAÇÃO CRUZADA DA BOVINOCULTURA


**Bovinocultura e Avicultura de Postura**




**Bovinocultura e Lácteos**



**Bovinocultura e Pescados**



**Bovinocultura e Suinocultura**



# MAIORES CORRELAÇÕES

---

- ❖ Tendo analisado os gráficos de autocorrelação e correlações cruzadas da série de Bovinocultura, vê-se que as principais correlações entre as cadeias (e seus respectivos Lags) são dados por:

Cadeia	Lags
Avicultura de Corte	Lag 0
Avicultura de Postura	Lag 9
Pescado	Lag 3
Pescado	Lag 10
Suinocultura	Lag 0
Bovinocultura	Lag 1

# AGENDA



Contexto

Objetivo

Técnicas Utilizadas

Testes Estatísticos

Série Temporal

Correlações

**Regressões**

# REGRESSÃO LASSO

---

- ❖ A Regressão Lasso tem o efeito de fazer com que alguns coeficientes (os menos importantes para o modelo) diminuam em módulo até ficar exatamente igual a zero
- ❖ A ideia aqui é inferir as correlações mais importantes entre as cadeias com base nas variáveis que restam.

# REGRESSÃO LASSO

---

- ❖ Generalização da Regressão Linear

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

- ❖ Fixado um  $\lambda > 0$ , queremos  $\boldsymbol{\beta}$  que minimize:

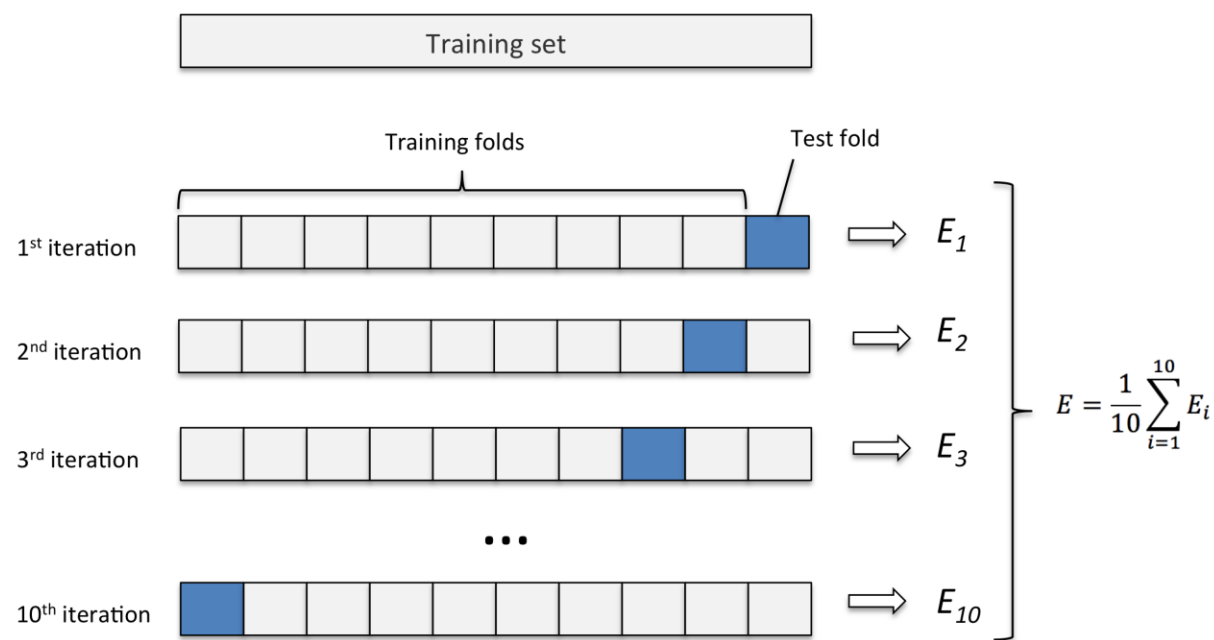
$$\min_{\boldsymbol{\beta}} \sum_{i=1}^n (y_i - \mathbf{X}_i\boldsymbol{\beta})^2 + \lambda \sum_{j=1}^p |\beta_j|.$$

- ❖ O estimador será dado por:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}.$$


# VALIDAÇÃO CRUZADA

- ❖ Antes de aplicar a Regressão Lasso, precisamos fixar um valor de  $\lambda$ ;
- ❖ Através de um método conhecido como validação cruzada, conseguimos escolher  $\lambda$  de tal forma que minimizamos o erro.



# VALIDAÇÃO CRUZADA

❖ Para nosso caso, fizemos validação cruzada com  $\text{nfolds} = 10$



	Measure: Mean-Squared Error			
	Lambda	Measure	SE	Nonzero
min	0.0504	2.955	1.067	8
1se	0.7489	3.976	1.625	2



# REGRESSÃO LASSO

❖ Os coeficientes obtidos para as variáveis através do modelo foram:

Library(glmnet)

Variáveis	Estimativas
(Intercept)	0.31262107
`Avicultura de Corte`	0.39843764
`Avicultura de Postura`	0
`Pescado`	-0.15329263
`Lácteos`	-0.1509418
`Suinocultura`	0.24605653
`Avicultura de Postura 9`	0.14932952
`Pescado 3`	-0.01311084
`Pescado 10`	0.01739267
`Bovinocultura 1`	0.35784156

# REGRESSÃO LASSO

❖ Os coeficientes obtidos para as variáveis através do modelo foram:

Library(lasso)

Variáveis	Estimativa	Erro Padrão	Valor Z	Pr(> Z )
(Intercepto)	0.28555	0.20359	1.403	0.160748
`Avicultura de Corte`	0.41319	0.11348	3.641	0.000271
`Avicultura de Postura`	0.04527	0.06032	0.750	0.452995
`Pescado`	-0.25994	0.11192	-2.323	0.020202
`Lácteos`	-0.20752	0.12319	-1.685	0.092067
`Suinocultura`	0.27996	0.21147	1.324	0.185555
`Avicultura de Postura 9`	0.17970	0.05358	3.354	0.000796
`Pescado 3`	-0.0226	0.10177	-0.217	0.828397
`Pescado 10`	0.07148	0.10156	0.704	0.481548
`Bovinocultura 1`	0.37949	0.09756	3.890	0.000100

# REGRESSÃO CLÁSSICA NO CONTEXTO DE SÉRIES TEMPORAIS

---

- ❖ A regressão simples no contexto de séries temporais pode ser expressa por:

$$x_t = \beta_0 + \beta_1 z_{t1} + \cdots + \beta_q z_{tq} + w_t = \beta' z_t + w_t.$$

- ❖ O erro de mínimos quadrados é dado por:

$$Q = \sum_{t=1}^n w_t^2 = \sum_{t=1}^n (x_t - \beta' z_t)^2,$$

- ❖ As estimativas dos coeficientes são explicadas por:

$$\hat{\beta} = \left( \sum_{t=1}^n z_t z_t' \right)^{-1} \sum_{t=1}^n z_t x_t.$$

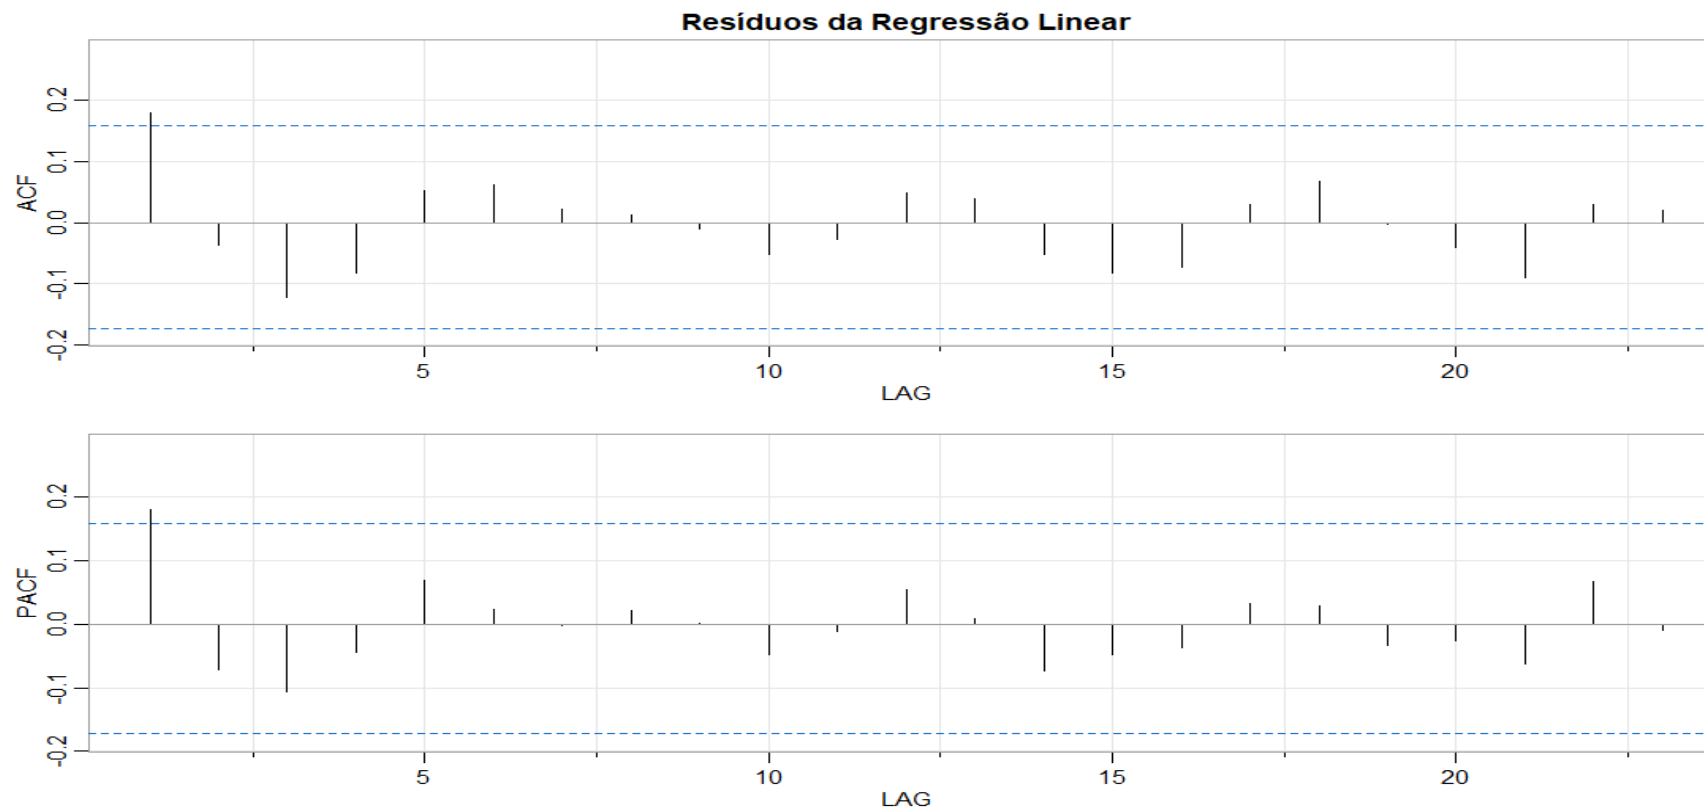
# REGRESSÃO CLÁSSICA NO CONTEXTO DE SÉRIES TEMPORAIS

❖ Os coeficientes obtidos para as variáveis através do modelo foram:

Variáveis	Estimativa	Erro Padrão	Valor t	Pr(> t )
(Intercepto)	0.28536	0.20364	1.401	0.163405
`Avicultura de Corte'	0.41328	0.11349	3.642	0.000384
`Avicultura de Postura'	0.04542	0.06035	0.753	0.452982
`Pescado'	-0.26037	0.11194	-2.326	0.021498
`Lácteos'	-0.20785	0.12322	-1.687	0.093939
`Suinocultura'	0.28048	0.21162	1.325	0.187266
`Avicultura de Postura 9'	0.17980	0.05358	3.356	0.001026
`Pescado 3'	-0.02202	0.10186	-0.216	0.829147
`Pescado 10'	0.07166	0.10163	0.705	0.481954
`Bovinocultura	0.37950	0.09758	3.889	0.000157

# REGRESSÃO CLÁSSICA NO CONTEXTO DE SÉRIES TEMPORAIS

- ❖ Agora precisamos analisar as funções de autocorrelação e autocorrelação parcial dos resíduos do modelo.



# REGRESSÃO COM ERROS AUTOCORRELACIONADOS

- ❖ O modelo de Regressão também pode ser escrito como

$$y_t = \sum_{j=1}^r \beta_j z_{tj} + x_t$$

- ❖  $x_t$  é um processo com alguma função de covariância  $\gamma_x(s, t)$ . Como nesse caso o resíduo do modelo é  $x_t$  o modelo com erros autocorrelacionados é dado por

$$y^* = Z^* \beta + \delta,$$

- ❖ Essa função é composta por

$$\Gamma = \{\gamma_x(s, t)\},$$

$$y^* = \Gamma^{-1/2} y, \quad Z^* = \Gamma^{-1/2} Z,$$

$$\delta = \Gamma^{-1/2} x.$$

- ❖ A estimativa do método quadrados ponderados é dada por

$$\hat{\beta}_w = (Z^{*'} Z^*)^{-1} Z^{*'} y^* = (Z' \Gamma^{-1} Z)^{-1} Z' \Gamma^{-1} y,$$

# REGRESSÃO COM ERROS AUTOCORRELACIONADOS

- ❖ Para o caso autoregressivo de ordem  $p$  temos

$$\phi(B)x_t = w_t, \quad \phi(B) = 1 - \phi_1 B - \dots - \phi_p B^p \quad BX_t = X_{t-1} \quad B^m X_t = X_{t-m}$$

- ❖ Portando a regressão fica

$$\underbrace{\phi(B)y_t}_{y_t^*} = \sum_{j=1}^r \beta_j \underbrace{\phi(B)z_{tj}}_{z_{tj}^*} + \underbrace{\phi(B)x_t}_{w_t}$$

- ❖ O erro é minimizado em função da soma de mínimos quadrados a seguir

$$S(\phi, \beta) = \sum_{t=1}^n w_t^2 = \sum_{t=1}^n \left[ \phi(B)y_t - \sum_{j=1}^r \beta_j \phi(B)z_{tj} \right]^2$$

- ❖ Os parametros são respectivamente

$$\phi = \{\phi_1, \dots, \phi_p\} \quad \beta = \{\beta_1, \dots, \beta_r\}$$


# REGRESSÃO COM ERROS AUTOCORRELACIONADOS

❖ Os coeficientes obtidos para as variáveis através do modelo foram:

Variáveis	Estimativa	Erro Padrão	Valor t	Pr(> t )
ar1	0.4691	0.1227	3.8246	2.00E-04
Intercept	0.4196	0.2895	1.4497	0.1495
`Avicultura de Corte`	0.5589	0.1131	4.9432	0
`Avicultura de Postura`	0.0076	0.054	0.14	0.8889
Pescado	-0.1639	0.0963	-1.7023	0.091
Lácteos	-0.1834	0.1454	-1.2614	0.2093
Suinocultura	0.3054	0.2012	1.5182	0.1313
Avicultura de Postura 9	0.1548	0.0492	3.1468	0.002
Pescado 3	0.0282	0.0856	0.329	0.7427
Pescado 10	0.1139	0.0844	1.3496	0.1794
Bovinocultura 1	0.0712	0.1194	0.596	0.5521



# REGRESSÃO COM ERROS AUTOCORRELACIONADOS



# TESTE DE LJUNG-BOX PARA ARIMA(p,d,q)

---

- ❖  $H_0$  : Dados são independentemente distribuídos (não tem autocorrelação)
- ❖  $H_1$  : Dados não são independentemente distribuídos (tem autocorrelação)
- ❖ A estatística de teste é dada por:

$$Q = n(n+2) \sum_{k=1}^h \frac{\hat{\rho}_k^2}{n-k}$$

Com

$$Q > \chi_{1-\alpha, h}^2$$

$\hat{\rho}_k$  := autocorrelação amostral no lag k

h := número de lags sendo testados

- ❖ Aplicando sobre os resíduos, passamos a testar se os erros são não correlacionados (são ruído branco). Aqui, os g.l são corrigidos para  $h - p - q$ .




# REGRESSÃO COM ERROS AUTOCORRELACIONADOS

❖ O modelo final fica com forma:

Variáveis	Estimativa	Erro Padrão	Valor z	Pr(> z )
ar1	0,526516959	0,094723828	5,558442603	2,72192E-08
`Avicultura de Corte`	0,541743138	0,106565796	5,083649347	3,70251E-07
`Suinocultura`	0,422422157	0,194655795	2,170098032	0,02999942
`Avicultura de Postura 9`	0,133101239	0,047602027	2,796125466	0,005171932

# REGRESSÃO COM ERROS AUTOCORRELACIONADOS

Residuals from Regression with ARIMA(1,0,0) errors



## Teste Ljung-Box

$Q^* = 2.7751$	$df = 6$	$p\text{-value} = 0.8365$
----------------	----------	---------------------------

# REGRESSÃO COM ERROS AUTOCORRELACIONADOS

❖ Temos então para o modelo final:

$$\underbrace{\phi(B)y_t}_{y_t^*} = \sum_{j=1}^r \beta_j \underbrace{\phi(B)z_{tj}}_{z_{tj}^*} + \underbrace{\phi(B)x_t}_{w_t},$$

Com:  $\phi(B) = 1 - 0.53B$

Sendo:  $\beta_1 = \alpha = 0.54$   $\beta_2 = \beta = 0.42$   $\beta_3 = \gamma = 0.13$

Temos:  $(1 - 0.53B)y_t = \sum \beta_j(1 - 0.53B)z_{tj} + (1 - 0.53B)x_t$

Por fim:

$$y_t = 0.54AVC_t - 0.29AVC_{t-1} + 0.42SUINO_t - 0.22SUINO_{t-1} + 0.13AVP_{t-9} - 0.07AVP_{t-10} + 0.53y_{t-1} + w_t$$

$$w_t \sim RB(0, \sigma_\epsilon^2)$$

# REGRESSÃO COM ERROS AUTOCORRELACIONADOS

---

❖ Passo a passo para regressão com erros autocorrelacionados:

1. Primeiramente, rodar a regressão ordinária (clássica) para  $y_t$  com  $z_{t1}, \dots, z_{tr}$  (considerando os erros como não correlacionados);
2. Guardar os resíduos  $\hat{x}_t = y_t - \sum_{j=1}^r \hat{\beta}_j z_{tj}$  ;
3. Identificar o(s) modelo(s) ARMA para os resíduos  $\hat{x}_t$  ;
4. Aplicar o método dos mínimos quadrados ponderados no modelo de regressão com erros autocorrelacionados usando o modelo especificado na etapa 3. ;
5. Inspeccionar os resíduos  $\hat{w}_t$  para verificar se os erros formados são do tipo ruído branco e caso necessário, ajustar um novo modelo.